

Regression discontinuity

Economía Aplicada - UdeSA

Paola Llamas y Tomás Pacheco

November 2024

Setup

Main Idea of Regression Discontinuity Design

- Regression Discontinuity Design (RDD) exploits the facts that:
 - Some rules are *arbitrary* and generate a *discontinuity* in treatment assignment.
 - The treatment assignment is determined based on whether a unit exceeds some threshold on a variable (**running variable**).

Motivating Example: Class Size Rule in Israel

USING MAIMONIDES' RULE TO ESTIMATE THE EFFECT OF CLASS SIZE ON SCHOLASTIC ACHIEVEMENT*

JOSHUA D. ANGRIST AND VICTOR LAVY


The twelfth century rabbinic scholar Maimonides proposed a maximum class size of 40. This same maximum induces a nonlinear and nonmonotonic relationship between grade enrollment and class size in Israeli public schools today. Maimonides' rule of 40 is used here to construct instrumental variables estimates of effects of class size on test scores. The resulting identification strategy can be viewed as an application of Donald Campbell's regression-discontinuity design to the class-size question. The estimates show that reducing class size induces a significant and substantial increase in test scores for fourth and fifth graders, although not for third graders.

- In Israel, a rule mandates that classes cannot exceed 40 pupils.
- When enrollment reaches 41 students, schools must open a second classroom.
- By comparing outcomes (e.g., test scores) just below and above this threshold, we can examine the effect of class size on learning outcomes.

Necesitamos hacer dos supuestos cuando hacemos RD:

1. Los individuos no pueden manipular la variable de discontinuidad Z (taxes?).
2. Las características de los individuos son funciones suaves de la asignación al tratamiento. Esto es, la variable de interés solo debe cambiar en el cutoff por el tratamiento.

Importante: RD tiene muy poca validez externa, dado que el efecto de tratamiento es **LOCAL** a la discontinuidad.



RD tiene dos enfoques distintos:

1. Sharp RD
2. Fuzzy RD

Sharp RD and Fuzzy RD

- In general, depending on enforcement of treatment assignment, RD can be categorized into two types:
 - **Sharp RD**: nobody below the cutoff gets the “treatment”, everybody above the cutoff gets it
 - **Fuzzy RD**: the probability of getting the treatment jumps discontinuously at the cutoff (NOT jump from 0 to 1)


Sharp RD

- **Treatment**

- Assignment variable (running variable): X_i
- Threshold (cutoff) for treatment assignment: c
- Treatment variable: D_i is

$$D_i = \begin{cases} 1 & \text{if } X_i \geq c \\ 0 & \text{if } X_i < c \end{cases}$$

Sharp design



A Simple RD Regression

- A simple RD regression is

$$Y_i = \alpha + \rho D_i + \gamma(X_i - c) + u_i$$

- Explanation of terms:
 - Y_i is the outcome variable
 - D_i is the treatment variable (independent variable)
 - X_i is the running variable
 - c is the value of the cutoff
 - u_i is the error term including other factors


Si escribimos los outcomes potenciales como una función lineal, los efectos pueden escribirse como:

$$E(Y_{0i}|X_i) = \alpha + \gamma(X_i - c)$$

$$Y_{1i} = Y_{0i} + \rho$$

- Intuitively, we are interested in the discontinuity in the outcome at the **discontinuity** in the treatment assignment.
- Unobservable.
- RD estimates as:

$$\hat{\rho}_{SRD} = \lim_{\epsilon \rightarrow 0} E[Y_i \mid X_i = c + \epsilon] - \lim_{\epsilon \rightarrow 0} E[Y_i \mid X_i = c - \epsilon]$$



Fuzzy RD

- Some individuals above cutoff do NOT get treatment and some individuals below cutoff do receive treatment.
- The result is a research design where the discontinuity becomes an instrumental variable for treatment status.
- Now, LATE estimated: average treatment effect on compliers.





Figure is from Roberts and Whited (2010)



Treatment probability
increases at x'

Some untreated for $x > x'$
and some treated for $x < x'$

Treatment is not
purely driven by x

Figure is from Roberts and Whited (2010)

Continuity Assumption

- **Continuity Assumption**

- $E[Y_{1i} | X_i]$ and $E[Y_{0i} | X_i]$ are continuous at $X_i = c$
- Assume potential outcomes do not change at cutoff.
- This means that except for treatment assignment, all other unobserved determinants of Y_i are continuous at cutoff c .
- This implies no other confounding factor affects outcomes at cutoff c .
- Any observed discontinuity in the outcome can be attributed to treatment assignment.


Intuition: it allows us to use the average of the outcomes of the units below the cutoff as a good counterfactual for the units above.

Continuity Assumption


- **Continuity** is a natural assumption but could be **violated** if:
 1. There are differences between the individuals who are just below and above the cutoff that are **NOT** explained by the treatment.
 - The same cutoff is used to assign some other treatment.
 - Other factors also change at cutoff.
 2. Individuals can **fully manipulate** the running variable in order to gain access to the treatment or to avoid it. Strategic behaviour.

Non-linearities!

- Sometimes $E(Y_{0i}|X_i)$ is non linear.



- RD validity depends on the assumption that polynomials represent correctly $E(Y_{0i}|X_i)$




Falsification methods


Falsification methods

- Covariate balance: el tratamiento no tiene que tener ningún efecto en las covariables cuyos valores son realizados antes de la asignación al tratamiento.
- Density of running variable: si las personas no pueden manipular el cutoff, esperaríamos que la proporción por arriba y por debajo del cutoff sean iguales.
- Cutoffs alternativos: se define otro cutoff y se utilizan las observaciones que están por arriba y por abajo.
- Distintos bandwidths o windows: si los efectos cambian mucho o desaparecen cuando se elige el vecindario, hay que tener mucha cautela al interpretar resultados.

Sorting behavior: Manipulation of a poverty index in Colombia

- Adriana Camacho and Emily Conover (2011) "Manipulation of Social Program Eligibility" AEJ: Economic Policy
- A poverty index is used to decide eligibility for social programs
- The algorithm to create the poverty index becomes public during the second half of 1997.





Estimation procedure and inference

Existen dos enfoques principales para analizar e interpretar RDs.

1. Ver el estimador de RD como diferencia de ordenadas.
 - Se basa en la continuidad de la función y utiliza métodos de polinomios locales.
2. Ver el estimador de RD como diferencia de promedios.
 - El segundo se basa en hacer el supuesto de independencia de forma local (en una window) y usar las ideas/herramientas de la literatura de diseño experimental.

1. Local polynomial methods


- Enfoques utilizados
- Selección del bandwidth
- Robust Bias correction
- Intervalos de confianza

2. Local randomization methods

- Interpretar RD como una randomización local en una ventana alrededor del cutoff
- Diferencias a la estimación de polinomios local
- Selección de la ventana
- Estimación e inferencia usando métodos basados en la randomización.

Local polynomial methods

Dentro de este grupo de métodos, se tiene el enfoque de **polinomio global** (global polynomial approach) y el **conventional local polynomial approach**.




Conventional local polynomial approach

Solo le da peso a observaciones que están a determinada distancia del cutoff. Steps:

1. Se aproximan funciones de regresión para los tratados y controles de forma local
2. $E(Y_i|X_i = x)$ es aproximada en un vecindario de x_0 por un polinomio
3. Se estima el polinomio local:
 - Hay que elegir el bandwidth para quedarse con las observaciones en $[x_0 - h, x_0 + h]$
 - Elegir la función kernel para ponderar las observaciones,
 $w_i = K\left(\frac{x_i - x_0}{h}\right)$
 - Elegir el orden del polinomio.

Conventional local polynomial approach



Elección del bandwidth

Recordar que la elección del bandwidth implica un trade off sesgo-varianza. Distintas alternativas:

1. Elección ad-hoc.
 - No se usa: (i) es subjetivo, (ii) no es comparable, (iii) es discrecional.
2. Original MSE [Imbens & Kalyanaraman, 2012]
 - Obsoleto: IK proposed a first-generation plug-in rule leading to a bandwidth selector based on a simple reference model and (possibly inconsistent) plug-in estimators.
3. Mean Square Error Optimal (MSE-optimal) [Calonico, Cattaneo Titiunik, 2014):
 - Tiene mejores propiedades asintóticas y de muestra finita comparadas con el MSE de IK.
 - h_{MSE} es óptimo para la estimación puntual, pero no lo es para hacer inferencia. Calonico, Cattaneo and Farrell (2018, 2019a, 2020) muestran cómo elegir el bandwidth para obtener intervalos de confianza minimizando el coverage error probability (CER).

El CE bandwidth óptimo está diseñado para minimizar el CER del estimador del intervalo, lo que es diferente a minimizar el MSE del estimador puntual. Por lo tanto, los bandwidths MSE y CE óptimos son complementarios. Ambos se utilizan en los trabajos empíricos.

Para más detalles: Cattaneo, M. D., Vazquez-Bare, G. (2016). The choice of neighborhood in regression discontinuity designs. *Observational Studies*, 2(134), A146.

Recomendaciones (Cattaneo y Vazquez-Bare, 2016)

- Siempre usar un bandwidth (o window) que sea data-driven. Esto de objetividad y robustez dado que incorpora la estructura de los datos, tales como la densidad de las observaciones, la variabilidad de los datos y la curvatura de las funciones de regresión desconocidas.
- Elegir bandwidth o window selectors de acuerdo a los supuestos hechos, que deben estar explicados. No existe una forma de elegir los bandwidths para todos los objetivos usando polinomios locales.
- No utilizar el mismo vecindario para diferentes outcomes, covariables, estimación e inferencia o falsification methods. Si se utiliza el mismo vecindario para diferentes objetivos, no se van a tener en cuenta la estructura de los datos, lo que conlleva que los resultados no creíbles por utilizar métodos inválidos.

Estimación e inferencia: elección polinomio

- La estimación puntual se suele hacer utilizando polinomios locales, es decir, estimando un polinomio de grado p de cada lado del cutoff. Solo para observaciones dentro del bandwidth.
- En esta aproximación siempre se incluye una forma de ponderar los datos, es decir, un kernel. En la práctica, estimar polinomios de alto grado puede hacer que se tenga un comportamiento errático. (Calonico, Cattaneo and Titiunik, 2015a, p. 1756-57). Además, los polinomios globales pueden llevar a que la ponderación de las observaciones sea contraintuitivo (Gelman and Imbens, 2019)
- Elecciones comunes: $p = 1$ o $p = 2$.

- OLS asume que el polinomio elegido para la estimación es la forma correcta de la función, mientras que los métodos de polinomios locales lo ven como una aproximación a la verdadera función de regresión.
- Por lo tanto, con el uso de polinomios locales ya sabemos que la estimación va a contener cierto error de aproximación o sesgo de especificación.
- Calonico, Cattaneo and Titiunik (2014b) proponen una forma de construir un estadístico t que corrige el sesgo del estimador. A esto se lo llama como **robust bias-corrected inference**

Continuity-based framework: summary

1. Key assumptions:
 - 1.1 Random potential outcomes drawn from an infinite population
 - 1.2 The regression functions are continuous at the cutoff
2. Bandwidth selection:
 - 2.1 Systematic, data-driven selection based on non-parametric methods
 - 2.2 Optimality criterion: MSE, coverage error
3. Estimation:
 - 3.1 Nonparametric local polynomial regression within bandwidth
 - 3.2 Choice parameter: order of the polynomial, weighting method (kernel)
4. Inference:
 - 4.1 Large-sample normal approximation
 - 4.2 Robust, bias corrected

Local Randomization Framework

Idea: en vez de suponer que las funciones de regresión son continuas alrededor del cutoff, este enfoque se basa en la idea de que, cerca del cutoff el tratamiento puede interpretarse como si la asignación fuese random. El enfoque formal fue diseñado por Cattaneo, Frandsen and Titiunik (2015).

Suponemos que existe una ventana W_0 alrededor del cutoff en donde se cumplen las siguientes dos condiciones:

- Unconfunded assignment: la distribución del score dentro de la ventana no depende de los outcomes potenciales.
- Exclusion restriction: el outcome potencial no depende de la running variable dentro de la ventana, sino que el efecto se da solo a través del tratamiento. Esta condición requiere que los outcomes potencial no estén relacionados con el score.

Dependiendo de la cantidad de observaciones disponibles dentro de la ventana, el análisis experimental puede seguir dos diferentes enfoques:

- Randomization inference (Fisherian)
- Large sample

- No conocemos la ventana, por lo que tenemos que estimarla.
- Cattaneo, Frandsen and Titiunik (2015) proponen usar un mecanismo de selección de la ventana basado en la idea de que en un experimento randomizado, la distribución observada de las covariables tiene que ser similar en tratados y controles. Entonces, si el supuesto local es plausible en cualquier ventana, tiene que existir una ventana en la que no podemos rechazar la hipótesis de que las características observables entre tratados y controles, son similares.

La idea es elegir un test que compare las diferencias en un vector de covariables entre grupos, como la diferencia de medias del test de Kolmogorov-Smirnov:

- Hay que comenzar con una ventana chica.
 - Debe contener suficientes observaciones para tener potencia.
 - El número mínimo de observaciones va a depender de los datos.
 - Aproximadamente debería haber, como mínimo, 10 observaciones en cada grupo.
- Dentro de la ventana inicial, el investigador lleva a cabo un test en el que la hipótesis nula es que las características están balanceadas.
- Si no se rechaza H_0 , se aumenta el tamaño de la ventana.
- Se elige la ventana más ancha en la que la hipótesis nula no se haya rechazado.

Local randomization framework: summary

1. Key assumptions:
 - 1.1 There exists a window W_0 in which the treatment assignment mechanism satisfies two conditions:
 - Probability of receiving a particular score value in W_0 does not depend on the potential outcomes
 - Exclusion restriction or parametric relationship between $\mathbf{Y}$ and $\mathbf{X}$ in W_0
2. Window selection:
 - 2.1 Goal: find a window where the key assumptions are plausible.
 - 2.2 Iterative procedure to balance observed covariates between groups.
 - 2.3 Choice parameters: test statistic, stopping rule
3. Estimation:
 - 3.1 Difference in means between treated and controls within neighborhood OR
 - 3.2 Flexible parametric modeling to account for the effect of X_i
4. Inference:
 - 4.1 Fisherian randomization-based inference or large sample inference
 - 4.2 Conditional on sample and chosen window
 - 4.3 Choice parameter: test statistic, randomization mechanism in Fisherian