

Matching

Economía Aplicada - UdeSA

Paola Llamas y Tomás Pacheco

Semana 12

1. Repaso: modelos logit y probit
2. Matching

Repaso: modelos logit y probit

Modelos de elección binaria

Supongamos que queremos un modelo para:

$$p \equiv \Pr(Y = 1|X)$$

Ejemplos: la probabilidad de conseguir empleo dado que hizo una pasantía, probabilidad de aprobar Econometría dada la cantidad de horas de estudio o la probabilidad de fumar dadas las características de una persona.

Notar que

$$p \equiv E(Y|X)$$


Proof.

¿Por qué no estimar un modelo de probabilidad lineal (MLP) por MCO?

$$p = E(Y_i|X) = \alpha + \beta_1 X_{1i} + \dots + \beta_k X_{ki}$$

1. Por construcción es heterocedástico.
2. Predice efectos marginales constantes.

3 Genera predicciones inconsistentes con una probabilidad No está acotado entre 0 y 1!



- En vez de estimar un MLP vamos a usar modelos del tipo:

$$E(Y|X) = F(z) = F(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)$$

donde F es llamada función *link*, z es llamado índice y $0 < F(z) < 1$. Esto asegura que las probabilidades predichas se encuentren dentro el rango de las probabilidades


El modelo no-lineal lo escribiremos de la siguiente manera:

$$p = F(x'\beta)$$

donde la función *link* o $F(\cdot)$ tiene ciertas propiedades:

- $\lim_{z \rightarrow -\infty} F(z) = 0$
- $\lim_{z \rightarrow +\infty} F(z) = 1$
- $f(z) = dF(z)/dz > 0$

Probit y logit



Matching

- Matching es una estrategia **no experimental** (lo usamos en contextos donde no hay asignación aleatoria!).
- En un contexto no experimental podemos tener un **sesgo de selección** (treated y control son distintos más allá del tratamiento).
- Para que no haya sesgo de selección necesitamos que el grupo de tratados y control sean **similares**, excepto por la asignación a tratamiento.

Matching: va a crear un grupo control que sea lo *más parecido* al grupo tratado. Ej: universidad y salario.

Propensity score

Propensity score: se define como la probabilidad de ser tratado, condicional en los observables.

- $Dim(X) = 1$: probabilidad de ser tratado condicional en la edad.

$$p_i = P(T_i = 1|X_i) = F(\beta_0 + \beta_1 Edad_i) \rightarrow \hat{p}_i$$

- $Dim(X) = K$:

$$p_i = P(T_i = 1|X_i) = F(\beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki}) \rightarrow \hat{p}_i$$

Fortunately, propensity score matching solves "The Curse of Dimensionality"

Idea propensity score

i	Propensity score ($\hat{p}_i$)	Treated
1	0.75	1
2	0.75	0

Table 1: Matching

- Los individuos tienen la misma probabilidad de ser tratados. El hecho de que uno haya sido tratado y otro no se puede considerar como **aleatorio**.
- A través del propensity score, matcheamos tratados y controles.

Ejemplo X unidimensional

$$p_i = P(T_i = 1|X_i) = F(\beta_0 + \beta_1 \text{Edad}_i) \rightarrow \hat{p}_i$$

- Supongamos que todos los tratados tienen 20 años. Y todos los controles tienen 80 años.
- Para una persona de 20 años voy a predecir que es tratada.
- Para una persona de 80 años voy a predecir que no es tratada.
- Tratamiento **correlaciona perfectamente** con la edad (único observable en este caso), puedo predecir sin error $\Pr(Y = 1|X)$.

Propensity score matching

Matching consiste en usar el propensity score para elegir como control a las observaciones que más se parezcan al grupo de tratados.

Existen distintas formas de hacerlo:

- Nearest neighbor.
- Stratification.
- Radius.
- Kernel.
- Common support.

Nearest neighbor: 1:1

Elegimos como contrafactual de cada unidad tratada la observación más similar en el grupo de control.

- Problema: puede descartar un gran número de observaciones y, por lo tanto, reducir el power.

Nearest neighbor: 1:1

The closest comparison individual forms the singleton matched set M_i and is the one for whom the following is true:

$$M_i = \left\{ j \in C \mid j = \arg \min_j \|p_i - p_j\| \right\}$$

where the term $\|p_i - p_j\|$ denotes the Euclidean distance between propensity scores.

If Y_j is the observed outcome of the chosen neighbor and N_T the number of treated individuals:

$$\hat{\beta}_{PS}^{ATT} = \sum_{i \in T} (Y_i^T - Y_j^C) \frac{1}{N_T}$$

Nearest neighbor: 1:N

Para cada unidad tratada, encontramos las k observaciones más cercanas (definimos k a priori) en el grupo de control.

- Una observación de control puede ser utilizada múltiples veces.
- En caso de empates, se utilizan todas las observaciones empatadas como matches.

Nearest neighbor: 1:N

$$\hat{\beta}_{PS}^{ATT} = \sum_{i \in T} (Y_i^T - \hat{Y}_j^C) \frac{1}{N_T}$$


where:


$$\hat{Y}_j^C = \sum_{i \in C(i)} W_{ij} Y_j^C$$

- $C(i)$ is the set of neighbors of the treated observation i (based on PS).
- W_{ij} is the weight placed on untreated individual j .

Stratification

- Dividir a las observaciones en grupos según el PS.
- Chequear si tratados y control son similares en cada grupo. Si no lo son, dividir en grupos más pequeños.
- Dentro de cada grupo, correr la regresión (diferencia de medias de PS).
- El parámetro de interés será un promedio ponderado de las estimaciones de cada grupo.





- Intervals $k = 1, \dots, K$.
- $\hat{ATT}_k$: Difference between average outcome of treated and control within k^{th} interval.
- N_k^T number of treated individuals falling in interval k .
- N_k^C number of control individuals falling in interval k .
- N_T number of treated individuals.


$$\widehat{ATT}_k = \left(\sum_{i \in k} Y_i^T \frac{1}{N_k^T} \right) - \left(\sum_{j \in k} Y_j^C \frac{1}{N_k^C} \right),$$

The estimated ATT will be given by:

$$\hat{\beta}_{IM}^{ATT} = \sum_{k=1}^K \left(\widehat{ATT}_k \times N_k^T \right) \frac{1}{N_T}$$

Radius

Usamos como contrafactual de cada tratado los controles que estén a menos de cierta distancia (en general se usa 0.1).



- Cada tratado es *matcheado* con un promedio ponderado de controles.
- La ponderación que recibe cada control es decreciente en la distancia a la unidad tratada.


$$\hat{\beta}^{ATT} = \frac{1}{N_t} \sum_{i \in T} \left[Y_i^T - \sum_{j \in C(i)} W_{ij} Y_j^C \right]$$

where $W_{ij} = \frac{K\left(\frac{p_j - p_i}{h_n}\right)}{\sum_{j \in C(i)} K\left(\frac{p_j - p_i}{h_n}\right)}$

- As usual, depends on the distance between the propensity score of each comparison observation and the treated individual.
- Gaussian Kernel: uses all observations.

Common support

Eliminamos las observaciones cuyo propensity score está por fuera del soporte común.



Appendix

Demostración: Valor Esperado de una Variable Bernoulli

Demostración: Para una variable Bernoulli Y , $E(Y|X) = P(Y = 1|X)$.

Sea Y una variable aleatoria con distribución Bernoulli:

$$Y = \begin{cases} 1 & \text{con probabilidad } p, \\ 0 & \text{con probabilidad } 1 - p. \end{cases}$$

$$E(Y|X) = \sum_{y \in \{0,1\}} y \cdot P(Y = y|X).$$

Como Y solo toma valores 0 y 1, se reduce a:

$$E(Y|X) = 0 \cdot P(Y = 0|X) + 1 \cdot P(Y = 1|X).$$

$$E(Y|X) = P(Y = 1|X).$$